מערכת קונקורדנציה ואחזור טקסט עבור אוסף שירים באנגלית

המערכת תאפשר לטעון קבצי טקסט המכילים שירים באנגלית, לשמור בבסיס הנתונים מידע מובנה על כל שיר, לפרק את הטקסט לבתים, שורות ומילים. המערכת תאפשר למשתמש לבצע חיפושים, להציג מופעים של מילים וביטויים, ליצור קבוצות מילים ולהפיק נתונים סטטיסטיים.

המערכת תיכתב בשפת Python, בסיס הנתונים ימומש ב־Oracle, וממשק המשתמש ייבנה באמצעות Streamlit.

מטרת הפרויקט

מטרת הפרויקט היא לפתח מערכת המעניקה שירותי קונקורדנציה ואחזור טקסט עבור מספר מסמכים יחד.

המערכת תאפשר:

- טעינת קבצי טקסט מסוג txt.
- שמירת מידע מובנה על כל מסמך.
- פירוק המסמכים לבתים, שורות ומילים.
- חיפוש מסמכים על פי מידע מובנה.
- חיפוש מילים בתוך הטקסטים.
- הצגת כל המופעים של מילה מסוימת.
- הצגת ההקשר של כל מופע.
- הצגת מיקום המילה בכמה צורות שונות.
- חיפוש מילה לפי מיקומה.
- יצירת קבוצות מילים מותאמות אישית.
- שמירת ביטויים לשוניים וחיפוש המופעים שלהם.
- הצגת אינדקס מילים מלא או אינדקס לפי קבוצה.
- הצגת נתונים סטטיסטיים.
- גיבוי ושחזור הנתונים באמצעות XML.

סוג המסמכים

המערכת תעבוד עם אוסף של שירים באנגלית, כאשר כל שיר יישמר כקשר בין מספר מבני נתונים: שיר, בתים, שורות, מילים, אמנים, וכו׳.

לכל שיר יישמרו הנתונים הבאים:

- שם השיר
- אמן
- אלבום
- שנת פרסום
- הבתים, השורות והמילים של השיר
- תאריך טעינת השיר לבסיס הנתונים

ארכיטקטורת המערכת

המערכת תבנה בארכיטקטורה המחולקת לארבע שכבות עיקריות:

1. שכבת טעינה ועיבוד לטקסטים חדשים

המשתמש יטען למערכת קובץ txt המכיל שיר ופרטים נוספים על השיר שהמערכת תדרוש. תוכנית Python תקבל את הקובץ כקלט ותבצע:

- קריאת קובץ הטקסט.
- פירוק השיר לבתים, שורות ומילים.
- המרת מילים לאותיות קטנות לצורכי חיפוש.
- שמירת הצורה המקורית של כל שורה/בית לצורכי תצוגה.
- זיהוי מיקום כל מילה בתוך המסמך.
- טעינת הנתונים לבסיס הנתונים.

2. שכבת בסיס הנתונים

בסיס הנתונים יוקם ב־Oracle, הוא ישמור את פרטי המסמכים, המבנה הפנימי של כל מסמך, המילים והמופעים שלהן, קבוצות מילים, ביטויים לשוניים ונתונים נוספים.

3. שכבת היצוא/יבוא

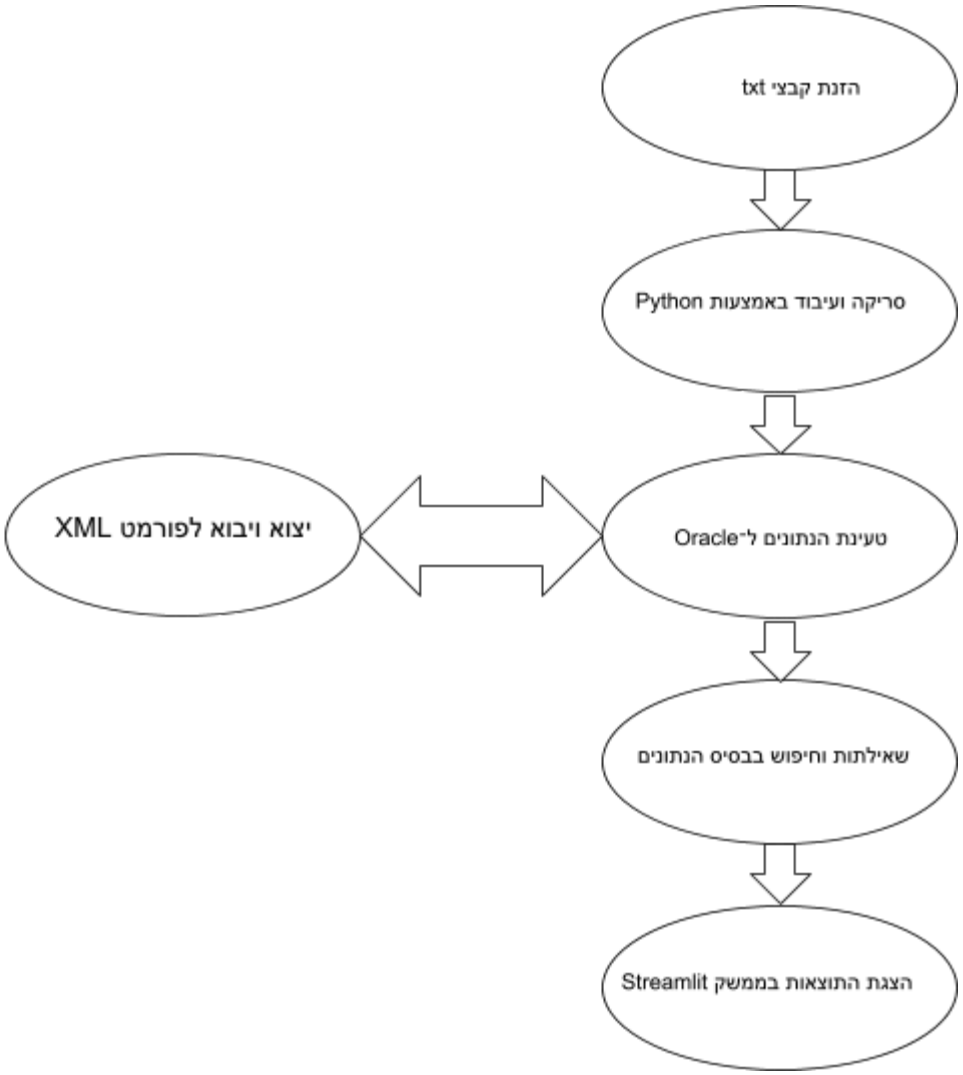
משתמש יוכל לגבות את כל בסיס הנתונים לקבצי XML ויוכל להשתמש בקבצי XML על מנת לטעון את בסיס הנתונים מחדש.

4. שכבת ממשק המשתמש

הממשק יבנה ב־Streamlit ויאפשר למשתמש לבצע את כל פעולות המערכת דרך הדפדפן.

הממשק יתחבר ל־Oracle באמצעות ספריית python-oracledb.

תרשים זרימת המערכת



תכנון בסיס הנתונים

טבלת SONGS

הטבלה תשמור מידע כללי על כל שיר.

שדות:

- song_id – מזהה ייחודי
- title – שם השיר
- artist – אמן
- album – שם האלבום
- publication_year – שנת פרסום
- upload_date – תאריך הטעינה למאגר הנתונים

טבלת STANZAS

הטבלה תשמור את הבתים של כל שיר.

שדות:

- stanza_id – מזהה ייחודי לבית
- song_id – מזהה השיר
- stanza_number – מספר הבית בתוך השיר

טבלת LINES

הטבלה תשמור את השורות של כל שיר.

שדות:

- line_id – מזהה ייחודי לשורה
- stanza_id – הבית שאליו שייכת השורה
- song_id – השיר שאליו שייכת השורה
- global_number – מספר השורה הכללי בתוך השיר
- local_number – מספר השורה בתוך הבית
- Number_of_words - מספר במילים בשורה
- text – תוכן השורה

טבלת WORDS

הטבלה תשמור כל מילה ייחודית פעם אחת.

שדות:

- word_id – מזהה ייחודי
- text – המילה לאחר ניקוי והמרה לאותיות קטנות
- length – מספר התווים במילה

טבלת WORD_OCCURRENCES

הטבלה תשמור כל מופע של מילה בטקסט.

שדות:

- occurrence_id – מזהה ייחודי
- word_id – מזהה המילה
- song_id – מזהה השיר בו מופיעה המילה
- stanza_id – מזהה הבית בו מופיעה המילה
- line_id – מזהה השורה בה מופיעה המילה
- word_position_in_line – מיקום המילה בתוך השורה
- word_position_in_song – מיקום כללי של המילה בשיר

טבלת WORD_GROUPS

הטבלה תשמור קבוצות מילים שהוגדרו על ידי המשתמש.

שדות:

- group_id – מזהה קבוצה
- group_name – שם הקבוצה
- description – תיאור הקבוצה
- creation_date – תאריך יצירה

טבלת GROUP_WORDS

טבלת קישור בין קבוצות למילים.

שדות:

- group_id
- word_id

מילה אחת תוכל להשתייך לכמה קבוצות, וכל קבוצה תוכל להכיל כמה מילים.

טבלת PHRASES

הטבלה תשמור ביטויים שהוגדרו על ידי המשתמש.

שדות:

- phrase_id
- phrase_text
- phrase_name
- creation_date

טבלת PHRASE_OCCURRENCES

הטבלה תשמור את המופעים שנמצאו עבור כל ביטוי.

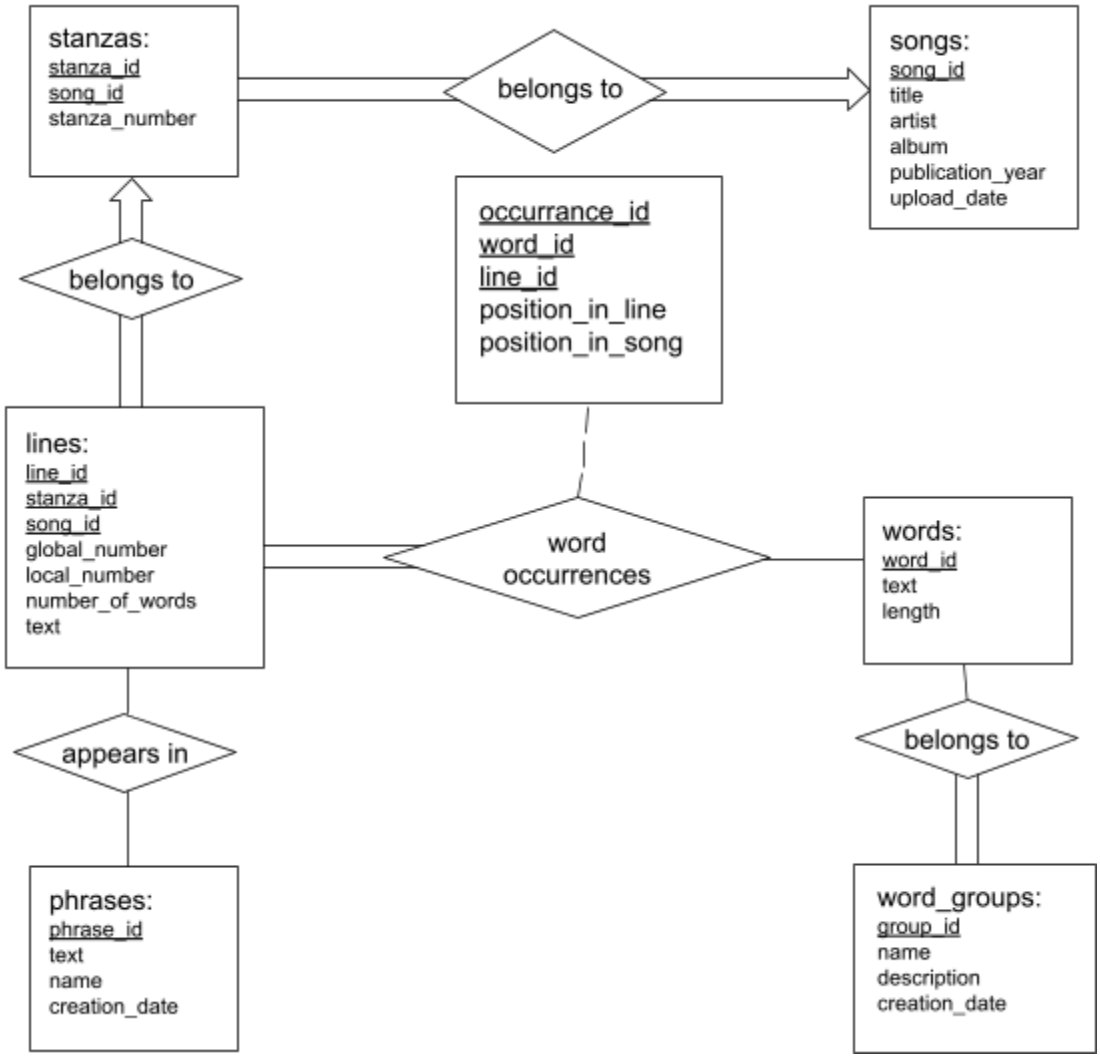
שדות:

- phrase_occurrence_id
- phrase_id
- song_id
- line_id
- start_word_position

קשרים עיקריים בין הטבלאות

- לכל שיר חייב להיות לפחות בית אחד
- כל בית מופיע בשיר אחד
- לכל בית חייבת להיות לפחות שורה אחת
- לכל שורה חייבת להיות לפחות מילה אחת
- כל שורה מופיעה בבית אחד

- לכל מילה יכולים להיות מופעים רבים בשירים/בתים/שורות או בלי מופעים כלל
- לכל קבוצת מילים חייבת להיות מילה אחת לפחות
- כל מילה יכולה להשתייך לכמה קבוצות
- לכל ביטוי יכולים להיות מופעים רבים או ללא מופעים כלל
- כל מופע של ביטוי מופיע בשורה.



פונקציונליות המערכת

1. טעינת מסמך חדש

המשתמש יבחר קובץ txt ויזין את פרטי השיר:

- שם השיר
- שם האמן
- שם האלבום
- שנת פרסום

המערכת תבדוק שהקובץ תקין, תקרא אותו, תפרק אותו לבתים, שורות ומילים ותכניס את הנתונים לטבלאות המתאימות.

2. הצגת כל המסמכים

המערכת תציג רשימה של כל השירים שנטענו.

לכל מסמך יוצגו פרטים כגון:

- שם השיר
- שם האמן
- אלבום
- שנת פרסום
- מספר בתים
- מספר שורות
- מספר מילים

3. חיפוש לפי מידע מובנה

המשתמש יוכל לחפש שירים לפי:

- שם השיר
- שם האמן
- שם האלבום
- שנת פרסום

4. חיפוש מילה

המשתמש יזין מילה, והמערכת תציג:

- באילו שירים היא מופיעה.
- כמה פעמים היא מופיעה בכל שיר.
- מספר המופעים הכולל.
- המיקום של כל מופע.
- ההקשר של כל מופע.

5. הצגת ההקשר

עבור כל מופע של מילה, יוצגו:

- השורה שבה נמצאת המילה.
- השורה שלפניה - אם קיימת.
- השורה שאחריה - אם קיימת.

6. הצגת אינדקס מילים

המערכת תציג את כל המילים הקיימות בבסיס הנתונים לפי סדר אלפביתי.

לכל מילה יוצגו השירים והמיקומים בהם היא מופיעה.

המיקום יוצג לפחות בשתי צורות:

1. מספר שורה כללי בשיר.
2. מספר בית ומספר שורה בתוך הבית.

7. חיפוש לפי מיקום

המשתמש יוכל לבחור שיר ולהזין:

- מספר שורה כללי.
- או מספר בית ומספר שורה בבית.
- ובמידת הצורך מיקום מילה בתוך השורה.

המערכת תציג את המילה או השורה הנמצאת באותו מיקום.

8. יצירת קבוצות מילים

המשתמש יוכל:

- ליצור קבוצה חדשה.
- לתת לקבוצה שם ותיאור.
- להוסיף מילים לקבוצה.
- להסיר מילים מקבוצה.
- להציג את כל המילים בקבוצה.
- להציג את כל המופעים של מילות הקבוצה בטקסטים.

9. הגדרת ביטויים לשוניים

המשתמש יוכל להגדיר ביטוי המורכב מכמה מילים ברצף.

לדוגמה: love is in the air

המערכת תחפש את רצף המילים בכל השירים ותציג:

- באילו שירים הביטוי מופיע.
- כמה פעמים הוא מופיע.
- מיקום כל מופע.
- ההקשר שבו הופיע.

10. נתונים סטטיסטיים

המערכת תציג נתונים כגון:

- מספר השירים בבסיס הנתונים
- מספר הבתים בכל שיר
- מספר השורות בכל שיר
- מספר המילים בכל שיר
- מספר המילים הייחודיות
- אורך ממוצע של מילה
- מספר מילים ממוצע בשורה
- המילים השכיחות ביותר
- המילים הנדירות ביותר
- מספר המופעים של כל מילה
- מספר המילים בכל בית
- התפלגות אורכי המילים

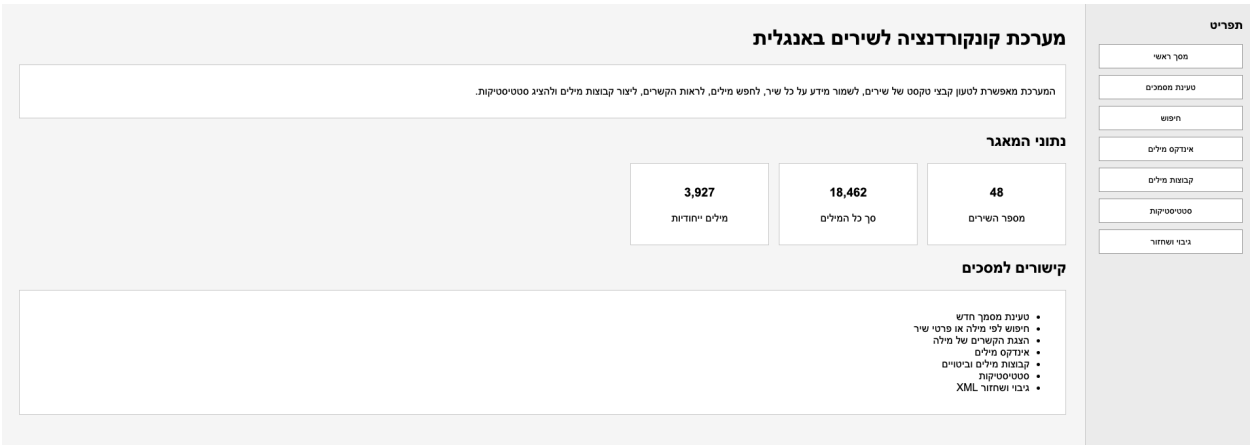
ממשק המשתמש

הממשק ייבנה באמצעות Streamlit ויחולק למספר מסכים.

מסך ראשי

יכלול:

- הסבר קצר על המערכת.
- מספר השירים במאגר הנתונים.
- מספר המילים הכולל.
- מספר המילים הייחודיות.
- קישורים לשאר מסכי המערכת.



מסך טעינת מסמכים

יכלול:

- בחירת קובץ.
- הזנת פרטי המסמך.
- כפתור טעינה.
- הודעת הצלחה או שגיאה.
- סיכום מספר הבתים, השורות והמילים שנקלטו.

מסך חיפוש

יכלול:

- חיפוש לפי מילה

- חיפוש לפי אמן
- חיפוש לפי שם שיר
- חיפוש לפי אלבום
- חיפוש לפי שנת פרסום
- הצגת תוצאות בטבלה

מסך הקשרים

יכלול:

- המילה שנבחרה.
- השיר שבו נמצאה
- הבית והשורה.
- השורה הקודמת
- השורה הנוכחית
- השורה הבאה
- מעבר למופע הבא והקודם

מסך אינדקס

יכלול:

- הצגת כל המילים לפי סדר אלפביתי
- סינון לפי מסמך
- סינון לפי קבוצת מילים
- הצגת מיקום כל מילה
- אפשרות יצוא לקובץ

מסך קבוצות

יכלול:

- יצירת קבוצה
- שינוי שם קבוצה
- הוספת מילים
- הסרת מילים
- הצגת מופעי הקבוצה

מסך ביטויים

יכלול:

- יצירת ביטוי חדש

- חיפוש הביטוי במסמכים
- הצגת כל המופעים
- הצגת ההקשר

מסך סטטיסטיקות

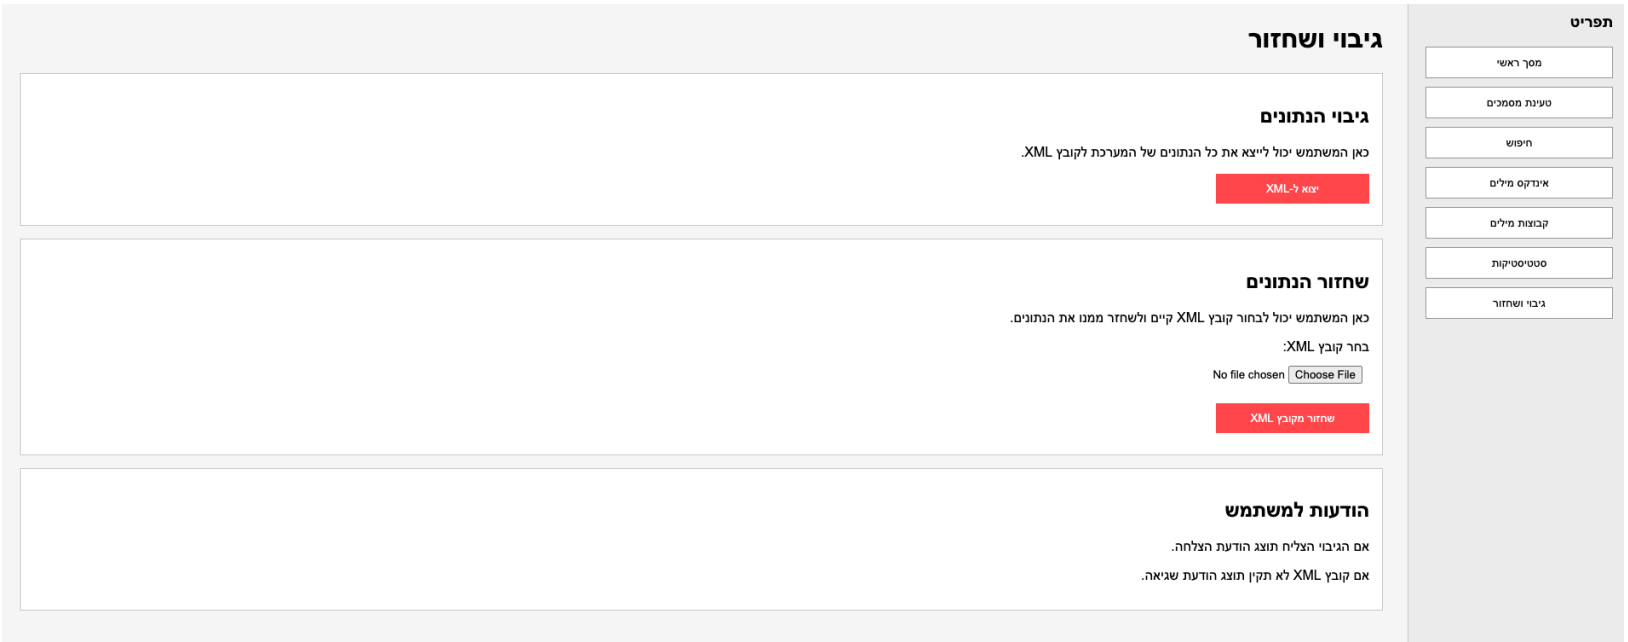
יכלול:

- נתונים מספריים
- טבלאות שכיחות
- גרפים בסיסיים
- בחירת מסמך מסוים או הצגת נתונים על כל המאגר

מסך גיבוי ושחזור

יכלול:

- יצוא כל הנתונים לקבצים בפורמט XML
- שחזור כל הנתונים מקובץ XML קיים



אילוצים בבסיס הנתונים

אלו האילוצים שיהיו במערכת:

- לכל טבלה יהיה מפתח ראשי
- מזהי מסמכים, בתים, שורות ומילים יהיו ייחודיים
- לא ניתן יהיה להוסיף בית ללא שיר קיים
- לא ניתן יהיה להוסיף שורה ללא בית ושיר קיימים
- לא ניתן יהיה להוסיף מופע של מילה ללא מילה ושורה קיימות
- שם קבוצה יהיה ייחודי
- לא ניתן יהיה לשייך אותה מילה לאותה קבוצה יותר מפעם אחת
- מספר בית יהיה חיובי שלם גדול מ0
- מספר שורה יהיה חיובי שלם גדול מ0
- מיקום מילה בשורה יהיה חיובי שלם גדול מ0
- לא ניתן יהיה להכניס שיר ללא שם, אמן ושנת פרסום
- לא ניתן יהיה להכניס מילה ריקה
- בכל שיר קיים בית אחד לפחות
- בכל בית קיימת שורה אחת לפחות
- בכל שורה קיימת מילה אחד לפחות

טיפול בשגיאות

המערכת תטפל במקרים הבאים:

- ניסיון לטעון קובץ שאינו מסוג txt
- קובץ ריק
- קובץ בעל קידוד לא תקין
- ניסיון לטעון אותו שיר פעמיים
- שיר ללא שם, אמן או שנת פרסום
- חיפוש מילה שאינה קיימת
- יצירת קבוצה בשם שכבר קיים
- הוספת מילה שאינה קיימת לקבוצה
- ביטוי ריק
- קובץ XML לא תקין
- כשל בחיבור לבסיס הנתונים
- שגיאה בעת ביצוע שאילתת SQL

במקרה של שגיאה תוצג למשתמש הודעה ברורה, והמערכת לא תשאיר נתונים חלקיים בבסיס הנתונים.